lab8

October 25, 2016

1 EE 379K: Lab 8

1.1 Rohan Nagar and Wenyang Fu

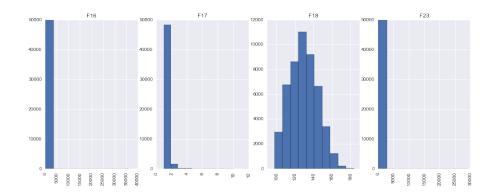
```
In [36]: import numpy as np
         import pandas as pd
         import matplotlib.pyplot as plt
         import seaborn as sns
         %matplotlib inline
         from sklearn.model_selection import (cross_val_score, train_test_split,
                                              GridSearchCV, RandomizedSearchCV)
         from sklearn.preprocessing import Imputer
         %load_ext autoreload
         %autoreload 2
/Users/rohannagar/anaconda/lib/python3.5/site-packages/matplotlib/__init__.py:872: UserWarning: axes.col
  warnings.warn(self.msg_depr % (key, alt_key))
In [37]: def to_file(filename, preds):
             with open(filename, 'w') as f:
                 f.write('Id,Probability\n')
                 for num, pred in zip(range(1,101504), preds):
                     f.write('{},{}\n'.format(num, pred))
```

2 Question 1

Some of the features we gave you are pure noise. Which ones? Find them and remove them.

2.1 The features F1, F6-9, F11-13, F16-18 are noise

```
else:
                       df[col].hist(axes=ax)
                       plt.xticks(rotation="vertical")
              plt.subplots_adjust(hspace=0.7, wspace=0.2)
              plt.show()
In [45]: train = pd.read_csv('data/train_final.csv')
         test = pd.read_csv('data/test_final.csv')
In [52]: train_noisy = train.ix[:, ['F1', 'F6', 'F11', 'F12', 'F13', 'F16', 'F17', 'F18', 'F23']]
         show_feature_dist(train_noisy)
     40000
                       40000
     30000
                       30000
                                                          30000
                       20000
                                         4000
     10000
```



In [48]: # Help from: http://stackoverflow.com/questions/13129618/histogram-values-of-a-pandas-series

```
import numpy as np
         bins=f2_uniques
         count, division = np.histogram(train.ix[:, 'F2'], bins=bins)
         print(count)
[47470 1905
               379
                     104
                                          6
                                                                  90]
In [51]: _, f8_uniques = get_unique_values(train, 'F8')
         bins=f8_uniques
         count, division = np.histogram(train.ix[:, 'F8'], bins=bins)
         print(count)
F8: [1, 2, 3, 4, 5, 6, 7, 8, 9]
Γ48281 1465
               188
                                                31
                      42
```

3 Question 2

Some of the features are noisy versions of other features. Which ones? Find them and remove them.

```
Out [103]:
               id
                    Y F1
                                 F2 F3 F4 F5 F6 F7
                                                          F8 ...
                                                                    F18
                                                                         F19
                                                                              F20
                                                                                   F21
          id
                1 NaN NaN
                                 NaN NaN NaN NaN NaN NaN ...
                                                                    NaN
                                                                         NaN
                                                                              NaN
                                                                                   NaN
          Y
              NaN
                    1 NaN
                                 Nan Nan Nan Nan Nan Nan ...
                                                                    NaN
                                                                         NaN
                                                                              NaN
                                                                                   NaN
          F1
              NaN NaN
                                 NaN NaN NaN NaN NaN NaN ...
                                                                    NaN
                                                                         NaN
                                                                              NaN
                                                                                   NaN
          F2
              NaN NaN NaN
                            1.000000 NaN NaN NaN NaN NaN NaN ...
                                                                    NaN
                                                                         NaN
                                                                              NaN
                                                                                   NaN
          F3
              NaN NaN NaN
                                       1 NaN NaN NaN NaN ...
                                NaN
                                                                    NaN
                                                                         NaN
                                                                              NaN
                                                                                   NaN
          F4
              NaN NaN NaN
                                 NaN NaN
                                           1 NaN NaN NaN NaN ...
                                                                    NaN
                                                                         NaN
                                                                              NaN
          F5
             NaN NaN NaN
                                NaN NaN NaN
                                               1 NaN NaN NaN ...
                                                                    NaN
                                                                         NaN
                                                                              NaN
                                                                                   NaN
          F6
              NaN NaN NaN
                                NaN NaN NaN NaN
                                                   1 NaN
                                                                                   NaN
                                                         \mathtt{NaN}
                                                                    NaN
                                                                         NaN
                                                                              NaN
                                NaN NaN NaN NaN
          F7
              NaN NaN NaN
                                                         {\tt NaN}
                                                                    NaN
                                                                         NaN
                                                                              NaN
                                                                                   NaN
                                                       1
          F8 NaN NaN NaN
                                NaN NaN NaN NaN NaN
                                                                         {\tt NaN}
                                                                    NaN
                                                                              NaN
                                NaN NaN NaN NaN NaN NaN ...
          F9 NaN NaN NaN
                                                                    {\tt NaN}
                                                                         NaN
                                                                              NaN
                                                                                   NaN
          F10 NaN NaN NaN
                                NaN NaN NaN NaN NaN NaN ...
                                                                    NaN
                                                                         NaN
                                                                              NaN
                                                                                   NaN
          F11 NaN NaN NaN
                                Nan Nan Nan Nan Nan Nan ...
                                                                         NaN
                                                                              NaN
                                                                                   NaN
                                                                    \tt NaN
          F12 NaN NaN NaN
                                Nan Nan Nan Nan Nan Nan ...
                                                                    NaN
                                                                         NaN
                                                                              NaN
          F13 NaN NaN NaN
                                NaN NaN NaN NaN NaN NaN ...
                                                                    NaN
                                                                         NaN
                                                                              NaN
                                                                                   NaN
          F14 NaN NaN NaN
                           0.992715 NaN NaN NaN NaN NaN NaN ...
                                                                    NaN
                                                                         NaN
                                                                              NaN
                                                                                   NaN
          F15 NaN NaN NaN
                                NaN NaN NaN NaN NaN NaN ...
                                                                    NaN
                                                                         NaN
                                                                              NaN
          F16 NaN NaN NaN
                                NaN NaN NaN NaN NaN NaN ...
                                                                         NaN
                                                                              NaN
                                                                                   NaN
                                                                    NaN
          F17 NaN NaN NaN
                                NaN NaN NaN NaN NaN NaN ...
                                                                    NaN
                                                                         NaN
                                                                              NaN
                                                                                   NaN
                                NaN NaN NaN NaN NaN NaN ...
          F18 NaN NaN NaN
                                                                      1
                                                                         NaN
                                                                              NaN
                                                                                   NaN
          F19 NaN NaN NaN
                                NaN NaN NaN NaN NaN NaN ...
                                                                    NaN
                                                                           1
                                                                              NaN
                                                                                   NaN
                                NaN NaN NaN NaN NaN NaN ...
          F20 NaN NaN NaN
                                                                    {\tt NaN}
                                                                         NaN
                                                                                1
                                                                                   NaN
          F21 NaN NaN NaN
                                NaN NaN NaN NaN NaN NaN ...
                                                                         NaN
                                                                              NaN
                                                                    NaN
          F22 NaN NaN NaN
                                NaN NaN NaN NaN NaN NaN ...
                                                                         NaN
                                                                              NaN
                                                                                   NaN
                                                                    NaN
          F23 NaN NaN NaN
                                       1 NaN NaN NaN NaN ...
                                                                              NaN
                                                                    NaN
                                                                         NaN
          F24 NaN NaN NaN
                                NaN NaN NaN NaN NaN NaN ...
                                                                    NaN
                                                                         NaN
                                                                              NaN
                                                                                   NaN
          F25 NaN NaN NaN
                           0.986766 NaN NaN NaN NaN NaN NaN ...
                                                                    NaN
                                                                         NaN
                                                                              NaN
                                                                                   NaN
          F26 NaN NaN NaN
                                 NaN NaN NaN NaN NaN NaN ...
                                                                      1
                                                                         NaN
                                                                              NaN
                                                                                   NaN
          F27 NaN NaN NaN
                                 NaN NaN NaN NaN NaN NaN ...
                                                                    {\tt NaN}
                                                                         NaN
                                                                              \mathtt{NaN}
```

```
F22
                  F23
                        F24
                                    F25
                                          F26
                                                F27
            NaN
                  NaN
                        NaN
                                    NaN
                                          NaN
                                                NaN
id
Y
            NaN
                  NaN
                        NaN
                                    NaN
                                          NaN
                                                NaN
F1
                                          NaN
                                                {\tt NaN}
            NaN
                  NaN
                        NaN
                                    NaN
F2
            NaN
                  NaN
                        NaN
                              0.986766
                                          NaN
                                                NaN
F3
            NaN
                    1
                        NaN
                                    NaN
                                          NaN
                                                NaN
F4
                                    NaN
            NaN
                  NaN
                        NaN
                                          NaN
                                                NaN
F5
            NaN
                  NaN
                        NaN
                                    \mathtt{NaN}
                                          \mathtt{NaN}
                                                NaN
F6
            NaN
                  NaN
                        NaN
                                    NaN
                                          NaN
                                                NaN
F7
            NaN
                  NaN
                        NaN
                                    NaN
                                          NaN
                                                NaN
F8
            NaN
                  NaN
                        NaN
                                    NaN
                                          NaN
                                                NaN
F9
            NaN
                  NaN
                        NaN
                                    NaN
                                          \tt NaN
                                                NaN
F10
     0.428354
                  NaN
                        NaN
                                    NaN
                                          NaN
                                                NaN
F11
            NaN
                  NaN
                        NaN
                                    NaN
                                          NaN
                                                NaN
F12
            NaN
                  NaN
                                    NaN
                                          NaN
                        NaN
                                                NaN
F13
            NaN
                  NaN
                        NaN
                                    NaN
                                          NaN
                                                NaN
F14
                              0.983338
            NaN
                  NaN
                                          NaN
                                                NaN
                        NaN
F15
            NaN
                  NaN
                        NaN
                                    NaN
                                          NaN
                                                NaN
F16
            NaN
                  NaN
                        NaN
                                    NaN
                                          NaN
                                                NaN
F17
            {\tt NaN}
                  NaN
                        NaN
                                    NaN
                                          NaN
                                                NaN
F18
            NaN
                  NaN
                        NaN
                                    NaN
                                             1
                                                NaN
F19
            NaN
                  NaN
                                    NaN
                                          NaN
                                                NaN
                        NaN
F20
                                          {\tt NaN}
            {\tt NaN}
                  {\tt NaN}
                        NaN
                                    {\tt NaN}
                                                NaN
F21
            NaN
                  NaN
                                    NaN
                                          NaN
                                                NaN
                        NaN
F22
     1.000000
                  NaN
                        NaN
                                    NaN
                                          NaN
                                                NaN
F23
            NaN
                    1
                        NaN
                                    NaN
                                          NaN
                                                NaN
F24
            {\tt NaN}
                  NaN
                                    NaN
                                          NaN
                                                NaN
                          1
F25
                              1.000000
            NaN
                  NaN
                        NaN
                                          NaN
                                                NaN
F26
                  NaN
            NaN
                        NaN
                                    NaN
                                             1
                                                NaN
F27
            NaN
                  NaN
                        NaN
                                    NaN
                                          NaN
                                                   1
[29 rows x 29 columns]
```

F3 and F23 are perfectly correlated. Also, F2, F14, and F25 are highly correlated with >.987 correlation score. We can say that these features are noisy versions of each other. We will try removing them in question 3 and see if it improves our score.

4 Question 3

Retrain your models using this information. Merge models with your lab partner and report your best private score. Does removing the noise features improve your performance?

```
X_test = test.drop(['id'], axis=1)
         ids = test['id']
In [64]: import xgboost as xgb
         xg = xgb.XGBClassifier(max_depth=4, n_estimators=1000, learning_rate=0.01,
                                 min_child_weight=5, gamma=.8, subsample=.4,
                                 reg_alpha=.5, colsample_bytree=.4, reg_lambda=.93)
         xg.fit(X_train, y_train)
         preds = xg.predict_proba(X_test)[:, 1]
         submit('submissions/q3/no_drops.csv', ids, preds)
4.0.1 Private score: 0.85926
This is our score using Raymond's best parameters for XGB
In [65]: feat_importances = xg.feature_importances_
         zipped_importances = zip(X_train.columns, feat_importances)
         sorted(zipped_importances, key=lambda x: x[1], reverse=True)
Out[65]: [('F23', 0.11621957),
          ('F27', 0.10260008),
          ('F3', 0.0959967),
          ('F19', 0.089888565),
          ('F18', 0.078250103),
          ('F22', 0.06661164),
          ('F25', 0.057614528),
          ('F14', 0.048947584),
          ('F26', 0.048204705),
          ('F2', 0.046801485),
          ('F10', 0.046141148),
          ('F11', 0.044737928),
          ('F6', 0.039620306),
          ('F16', 0.027073875),
          ('F21', 0.026330994),
          ('F9', 0.023607099),
          ('F5', 0.023359472),
          ('F20', 0.0033016922),
          ('F4', 0.002971523),
          ('F17', 0.0023111845),
          ('F7', 0.0021460999),
          ('F12', 0.0015683038),
          ('F1', 0.0014032192),
          ('F8', 0.0011555923),
          ('F15', 0.0011555923),
          ('F13', 0.00107305),
          ('F24', 0.00090796535)]
  Now we can drop the features that we were told are noisy.
```

X_train_drop = X_train.drop(['F1', 'F6', 'F11', 'F12', 'F13', 'F16', 'F17', 'F18'], axis=1)
X_test_drop = X_test.drop(['F1', 'F6', 'F11', 'F12', 'F13', 'F16', 'F17', 'F18'], axis=1)

In [73]: # Drop noisy features

4.0.2 Private Score: 0.85942

Dropping these definitely helped. Let's try to drop some more based on feature importances.

4.0.3 Private Score: 0.85914

We did a little worse than when we just dropped the features that we know are noise.

4.0.4 Private Score: 0.85809

Dropping F23 dropped our score by a lot, even though it was a duplicate of F3.

4.0.5 Private Score: 0.83660

These features are noisy but they help with the final prediction because their predictive power is strong, just as in the case of F23 and F3.

Let's merge our models.

```
In [101]: from sklearn.ensemble import VotingClassifier, RandomForestClassifier
          params = {'n_estimators': 500,
                    'max_features': 'sqrt',
                    'max_depth': 8,
                    'min_samples_split': 15,
                    'min_samples_leaf': 10
          rf = RandomForestClassifier(
                  n_estimators=params['n_estimators'],
                  max_features=params['max_features'],
                  max_depth=params['max_depth'],
                  min_samples_split=params['min_samples_split'],
                  min_samples_leaf=params['min_samples_leaf']
          eclf = VotingClassifier(estimators=[('rf', rf), ('xgb', xg)], voting='soft', n_jobs=-1)
          eclf.fit(X_train_drop, v_train)
          eclf.predict_proba(X_test_drop)[:, 1]
          submit('submissions/q3/merged.csv', ids, preds)
```

After merging our models together (The best XGB and the best Random Forest), we got the same private score of 0.85942. This is probably because our models are highly correlated.

5 Question 4

Write a post on the inclass Kaggle forums that contains some cool data science. Include your post in your report. Your post can be written by two people like your lab report.

6 Cool Data Science:

We tried a Bagging classifier using Raymond Wen's best XGBoost parameters. When we bagged 10 XG-Boost models and had them each sample from all of the data (with replacement), we noticed no noticeable improvement in leaderboard score. Perhaps a bagged estimator would also benefit from more model diversity, e.g., using 10 XGBoost models trained with different hyperparameters, and training them each on different portions of the data, and lastly ensembling them with a weighted majority vote based on CV-score. Wenyang successfully used this technique to improve his score by a fair margin of .00150, but it seems that Raymond's hyperparams don't benefit nearly as much from this technique.

```
In [102]: from sklearn.ensemble import BaggingClassifier

    classifier = BaggingClassifier(xg, n_estimators=30, n_jobs=-1)
    classifier.fit(X_train_drop, y_train)
    classifier.predict_proba(X_test_drop)[:, 1]
    submit('submissions/q3/bagged_30.csv', ids, preds)
```

7 Question 5

Have a look here:

https://www.kaggle.com/c/GiveMeSomeCredit

What is the best private score you can get for this competition? Include a screenshot of your submissions with scores in your lab report.

```
In [84]: cs_train = pd.read_csv('cs-training.csv', index_col=0)
         cs_test = pd.read_csv('cs-test.csv', index_col=0)
In [85]: # Drop dependent variable in test
         cs_test = cs_test.drop(['SeriousDlqin2yrs'], axis=1)
In [86]: # Fill missing with mean
         cs_train = cs_train.fillna(cs_train.mean())
         cs_test = cs_test.fillna(cs_train.mean())
In [87]: # Seperate dependent and independent
         cs_X_train = cs_train.drop(['SeriousDlqin2yrs'], axis=1)
         cs_y_train = cs_train['SeriousDlqin2yrs']
In [88]: from sklearn.preprocessing import FunctionTransformer
         # Perform a log transform on the data
         transformer = FunctionTransformer(np.log1p)
         cs_X_train = transformer.transform(cs_X_train)
         cs_test = transformer.transform(cs_test)
In [104]: import xgboost as xgb
          # XGB
          xg = xgb.XGBClassifier(max_depth=8, learning_rate=0.3, n_estimators=155,
                                  min_child_weight=0.6, subsample=1.0, colsample_bytree=0.45)
          xg.fit(cs_X_train, cs_y_train)
          preds = xg.predict_proba(cs_test)[:, 1]
          to_file('submissions/q5/xgb.csv', preds)
In [105]: from sklearn.ensemble import BaggingClassifier
          classifier = BaggingClassifier(xg, n_estimators=10, n_jobs=-1)
          classifier.fit(cs_X_train, cs_y_train)
          classifier.predict_proba(cs_test)[:, 1]
          to_file('submissions/q5/bagged_10.csv', preds)
   Our highest private score with 10 bagged XGBoost models is 0.855643. We did this by filling missing
values with the mean and also taking the log transform of all the features. We then fit an XGB and bagged
10 of them together. The screenshot is shown below.
In [106]: from IPython.display import Image
          Image("best_score.png")
Out[106]:
     Post-Deadline: Tue. 25 Oct 2016 22:19:56
                                                bagged_1
                                                          0.847774 0.855643
                                                0.csv
     Edit description
```